

An Investigation into Multi-Task Learning for POI Category Classification and Next-POI Prediction

Vitor H. O. Silva, Ingrid F. Almeida, Tarik S. Paiva, Germano B. Santos,
Fabrício A. Silva, Felipe T. Sousa
Laboratório de Inteligência em Sistemas Pervasivos e Distribuídos (NESPED-LAB), UFV,
Florestal, Brazil



Motivação & Problema

- LBSN $\Rightarrow$ entender e prever lugares visitados
- Tarefas complementares:
 - Classificação de Categoria do POI (semântica)
 - Previsão da Próxima Categoria (Next-POI) (sequencial)
- Pergunta: MTL ajuda quando treinamos as duas juntas?

Fundamentos & Trabalhos Relacionados

- MTL: compartilhar representações pode reduzir overfitting
- Em POI: há trabalhos multi-tarefa, mas geralmente tratam classificação e predição separadas
- Lacuna: avaliar MTL conjunto para classificação de categoria e próxima categoria

Dados & Métricas


- Gowalla (subset — Florida)
- 7 categorias: Community, Entertainment, Food, Nightlife, Outdoors, Shopping, Travel
- Avaliação: F1, Precisão, Recall (macro)
- Particionamento e protocolos seguindo literatura de LBSN

Embeddings & Preparação

- POI embeddings por grafo (atenção + contraste/auto-supervisão; DGI/GAT)
- Vizinhaça espacial e co-ocorrências para enriquecer o vetor do POI
- Sequências de check-ins $\Rightarrow$ inputs para os cabeçalhos de tarefas

Arquitetura MTL

- Encoder compartilhado com task embeddings + FiLM (condiciona camadas)
- Cabeças específicas:
 - *CategoryHead* (co-ocorrência semântica)
 - *NextHead* (dinâmica sequencial)
- Partição de parâmetros:
 - $\Theta_{\text{shared}} = \{\text{task_emb}, \text{film}, \text{shared_layers}\}$
 - $\Theta_{\text{specific}} = \{\text{category_encoder}, \text{next_encoder}, \text{CategoryHead}, \text{NextHead}\}$



Otimização Multi-Tarefa


- Nash-MTL para agregação de gradientes
- Inspiração: Nash Bargaining $\Rightarrow$ equilíbrio entre tarefas
- Objetivo: evitar que uma tarefa “domine” a outra

Baselines

- Single (uma tarefa por vez, mesma base)
- HMRRM (classificação de categoria – estado-da-arte do artigo de referência)
- MHA+PE (Next-POI – multi-head attention + positional encoding)

Resultados — Next-POI

Community: MHA+PE 35.83 (best) | Single 34.90 | MTL 34.79
Entertainment: Single 26.06 (best) | MHA+PE 25.48 | MTL 24.21
Food: MHA+PE 43.47 (best) | MTL 28.06 | Single 26.35
Nightlife: MTL 22.07 (best) | Single 21.79 | MHA+PE 1.55
Outdoors: Single 22.45 (best) | MTL 21.61 | MHA+PE 12.56
Shopping: MHA+PE 43.53 (best) | MTL 42.58 | Single 42.18
Travel: MTL 64.61 (best) | Single 64.32 | MHA+PE 26.91



Resultados — Classificação de Categoria

- Comparação com HMIRM (tabela no paper) + Single + MTL
- Desempenho misto: ganhos em algumas categorias e métricas, perdas em outras
- MTL competitivo, mas não consistentemente superior ao Single ou HMIRM

Convergência & Custo

- Category (Single): 16.26s | 3.8 épocas | 2.315 MFLOPs
- Next (Single): 18.71s | 3.2 épocas | 0.012 MFLOPs
- MTL: 80.88s | 3.2 épocas | 0.234 MFLOPs

Discussão: Quando o MTL ajuda?

- Transferência negativa sutil entre tarefas (dissimilaridade estrutural)
- Mismatch de representação (semântica vs. transições sequenciais)
- Arquitetura conservadora (hard-sharing + FiLM) pode limitar
- Insight: compatibilidade entre tarefas importa tanto quanto o otimizador

Conclusões & Próximos Passos

- Proposta: framework MTL com encoder compartilhado + cabeças específicas
- Resultados mistos: ganhos em Nightlife/Travel (Next-POI); sem superioridade geral
- Próximos passos:
 - Soft-sharing / Mixture-of-Experts entre tarefas
 - Ablations de embeddings (DGI/GAT vs. alternativas)
 - Curriculum/uncertainty weighting e task grouping

Título do slide (Fonte Segoe UI Black – tamanho 28 a 32)

Espaço destinado à descrição da apresentação. (Fonte Baskerville Old Face – tamanho 24 a 28)



Descrição da imagem. Fonte: