

# ST-MTLNet

## Representações Espaço-Temporais de Pontos de Interesse para Aprendizado Multitarefa

---

Tarik S. Paiva · Vitor H. O. Silva · Germano B. dos Santos · Fabrício A. Silva

**Apresentador: Vitor H. O. Silva**

NESPeD-LAB · Universidade Federal de Viçosa, Florestal, MG

**X Workshop de Computação Urbana (CoUrb 2026) · SBRC 2026**

25 de maio de 2026

# LBSNs, POIs e Aprendizado Multitarefa

## O que é um POI?

**Ponto de Interesse** (*Point of Interest*): uma localização física específica (ex: restaurante, parque) que desperta o interesse de um usuário para visitaç o.

## O que   MTL?

*Multi-Task Learning*: abordagem de redes neurais que treina m ltiplas tarefas de forma conjunta para compartilhar conhecimentos e melhorar a generaliza o.



N O-SEQUENCIAL

## Classifica o de Categoria de POI

Identificar a categoria sem ntica de um POI (ex: Comida, Lazer) a partir de suas caracter sticas est ticas.




SEQUENCIAL

## Predic o do Pr ximo POI

Prever a categoria ou local do pr ximo POI que o usu rio visitar  com base em seu h storico de movimentac o.


# De um Vetor Monolítico para Três Vetores Especializados



## HIPÓTESE

Representações desacopladas com encoders especializados capturam dimensões complementares que o DGI ignora.

# ST-MTLNet — Arquitetura



MTLNet interno (FiLM + ResBlocks + heads) preservado — isolamos o efeito da representação de entrada.

# Encoder Categórico

**Abordagem:** Hierarchical Graph Infomax (HGI) — maximização de informação mútua contrastiva sobre a hierarquia urbana POI → Região → Cidade.

## Como funciona

- Grafo: triangulação de **Delaunay** sobre as coordenadas dos POIs
- Codificadores **GCN + atenção (PMA)** nos níveis POI → Região → Cidade
- Treino contrastivo: discriminador bilinear  $\sigma(z_1^T W z_2)$ ; negativos por **corrupção** das features
- Objetivo:  $L = \alpha \cdot L_{\text{POI} \rightarrow \text{Região}} + (1 - \alpha) \cdot L_{\text{Região} \rightarrow \text{Cidade}}$  ( $\alpha = 0,5$ )
- Features de nó pré-treinadas com **Node2Vec + skip-gram** (módulo POI2Vec, nível fclass)
- Saída **64-d por POI**, concatenada com os demais (→ 192-d)

**Referências:** Huang et al., 2023 (HGI) · Veličković et al., 2019 (Deep Graph Infomax) · Grover & Leskovec, 2016 (node2vec / POI2Vec)

*Mesmo encoder categórico do MTLNet original; aqui isolado como uma das três modalidades de entrada. Detalhes técnicos no apêndice A6.*

## Por que HGI?

Captura a **vizinhança fina** (POIs adjacentes) e o **contexto urbano amplo** (região → cidade).

Reforça a separabilidade entre categorias semanticamente próximas — é a extensão hierárquica do Deep Graph Infomax (DGI).

# Encoder Temporal

**Abordagem:** Time2Vec — ativações periódicas aprendidas sobre (hora-do-dia, dia-da-semana), por check-in.

## Como funciona

$$\begin{aligned} f(\tau)[i] &= \omega_0 \cdot \tau + \varphi_0 & \text{se } i = 0 \\ &= \sin(\omega_i \cdot \tau + \varphi_i) & \text{se } 1 \leq i \leq D-1 \end{aligned}$$

- Entrada  $\tau = (\text{hora}/24, \text{dia}/7)$ ; **SineActivation 2→64** = 1 termo linear + 63 senoidais
- Projeção Linear 64→64; saída **64-d L2-normalizada**
- Termo linear → **tendência**; senoidais → **ciclos** com fase e frequência aprendidas

**Pré-treino:** auto-supervisionado contrastivo — BCE sobre  $\cos(z_i, z_j)/\tau$  ( $\tau = 0,3$ );  $\text{par+ } |\Delta t| \leq 1\text{h}$ ,  $\text{par- } \geq 24\text{h}$ .

**Referência:** Kazemi et al., 2019 — Time2Vec: Learning a Vector Representation of Time (arXiv:1907.05321).

*Mesma estrutura de loss contrastiva binária do encoder espacial (par+ janela curta, par- janela longa). Detalhes técnicos no apêndice A5.*

## Por que Time2Vec?

Generaliza encodings cíclicos fixos (sin/cos): fase e período são **aprendidos**, não fixados a priori.

Captura periodicidades não-óbvias (ex.: 4,5 dias) que um encoding fixo não representa.


# Duas Estratégias para Codificar Coordenadas

|             | SIREN                   | Sphere2Vec-M          |
|-------------|-------------------------|-----------------------|
| Estratégia  | senoidal local          | esférica multi-escala |
| Pressuposto | $\mathbb{R}^2$ contínuo | superfície esférica   |
| Forte em    | alta frequência         | distância geodésica   |
| Referência  | Rußwurm '24             | Mai '23               |

Mesma loss contrastiva binária ( $\text{par+} \leq 10 \text{ km}$ ,  $\text{par-} \geq 70 \text{ km}$ ) — isola o efeito de arquitetura. Detalhes técnicos no apêndice.

# Setup: Três Estados, Padrões Urbanos Distintos

| Estado     | Check-ins | POIs  | Usuários |
|------------|-----------|-------|----------|
| Florida    | 990 k     | 65 k  | 20 k     |
| California | 2,5 M     | 148 k | 36 k     |
| Texas      | 3,4 M     | 135 k | 37 k     |



Dataset Gowalla [Cho et al., '11] · F1 médio por categoria

5-fold estratificado por categoria · 80/20 (por POI para classificação · janelas não-sobrepostas para next-POI)

7 categorias × 3 estados = **21 combinações por tarefa**



# Classificação de Categoria — 21 / 21 Vitórias

≈ +21 pp F1  
21 / 21 vitórias

vs. baseline MTLNet · DGI (todas as 21)

FL +20,5 · CA +22,2 · TX +22,6


variante por variante: +18 a +24 pp

Ambos os encoders espaciais superam  
o DGI nas 21 combinações; **SIREN e  
Sphere2Vec-M empatam  
tecnicamente.**

Território decide por margem pequena:

SIREN em FL/CA, Sphere2Vec-M em

TX.



Médias de F1 sobre as 7 categorias, por estado. *Tabela completa por categoria (21 linhas) no apêndice A1.*

# Predição do Próximo POI — 15 / 21 Vitórias + 1 Empate

~72%

15 vitórias · 1 empate · 5 derrotas

vs. baseline DGI · 21 combinações


$\Delta$  médio por estado (pp):

**FL +1,7 · CA +2,0 · TX +5,1**

a média esconde o placar por categoria (A2)

Cenário heterogêneo, mas favorável.

Travel ilustra o limite: **DGI vence em Florida e California** (trajetórias longas favorecem o grafo), mas **ST-MTLNet vence em Texas**. Transições locais favorecem encoders contínuos.



Médias de F1 sobre as 7 categorias, por estado. Tabela completa por categoria (21 linhas) no apêndice A2.

# O Que Aprendemos — e o Que Ainda Falta

## Insights

- **Decompor a entrada por modalidade vence o monolito** — +21 pp F1 em categoria (21/21) e ~72% das combinações em next-POI
- **O ganho vem da decomposição, não do encoder espacial** — SIREN e Sphere2Vec-M empatam tecnicamente (~1 pp na média)
- **Território decide o melhor encoder espacial** — SIREN em FL/CA · Sphere2Vec-M em TX, por margem pequena

## Trabalhos futuros

- **Fusão híbrida grafo + contínua** — recuperar long-range / Travel
- **Ablação isolando cada encoder** — contribuição de espaço / tempo / categoria
- **Combinações além de concat** — gating, cross-attention, MoE / soft-sharing
- **Baselines modernos de next-POI** — LSTPM, GETNext, STAN, HMT-GRN

*Decompor a entrada por modalidade de sinal pode render mais que sofisticar o classificador central.*

# Para Levar

1

Encoders **desacoplados** > monolítico  
para tarefas com demandas distintas

2

~+21 pp F1 em categoria · ~72% vitórias  
em next-POI · 21/21 combinações em  
categoria

3

Não há encoder espacial universal —  
**território importa**

 Código: [github.com/TarikSalles/Spatial\\_Embeddings](https://github.com/TarikSalles/Spatial_Embeddings)

 Contato: [vitor.oliveira@ufv.br](mailto:vitor.oliveira@ufv.br)

## Obrigado — perguntas?

# Tabela completa — F1 Categoria (21 linhas)

| Estado · Categoria | Baseline (DGI) | ST-MTLNet · SIREN | ST-MTLNet · Sphere2Vec-M | Δ (melhor) |
|--------------------|----------------|-------------------|--------------------------|------------|
| FL · Food          | 55,47          | 73,22             | 72,10                    | +17,75     |
| FL · Shopping      | 62,96          | 77,48             | 76,30                    | +14,52     |
| FL · Nightlife     | 32,59          | 62,60             | 60,11                    | +30,01     |
| FL · Travel        | 45,49          | 64,89             | 63,40                    | +19,40     |
| FL · Outdoors      | 49,12          | 69,80             | 68,02                    | +20,68     |
| FL · Community     | 51,34          | 71,55             | 70,18                    | +20,21     |
| FL · Entertainment | 47,80          | 68,40             | 67,11                    | +20,60     |
| CA · Food          | 60,68          | 75,78             | 74,52                    | +15,10     |
| CA · Shopping      | 60,43          | 77,00             | 75,87                    | +16,57     |
| CA · Nightlife     | 26,81          | 60,78             | 58,93                    | +33,97     |
| CA · Travel        | 38,88          | 63,59             | 62,11                    | +24,71     |
| CA · Outdoors      | 43,21          | 66,02             | 64,80                    | +22,81     |
| CA · Community     | 49,55          | 70,12             | 69,02                    | +20,57     |
| CA · Entertainment | 45,12          | 66,80             | 65,49                    | +21,68     |
| TX · Food          | 54,31          | 72,40             | 73,10                    | +18,79     |
| TX · Shopping      | 62,70          | 78,80             | 79,67                    | +16,97     |
| TX · Nightlife     | 34,44          | 63,12             | 64,57                    | +30,13     |
| TX · Travel        | 39,37          | 63,90             | 64,73                    | +25,36     |
| TX · Outdoors      | 44,18          | 67,12             | 68,40                    | +24,22     |
| TX · Community     | 50,02          | 70,01             | 71,28                    | +21,26     |
| TX · Entertainment | 46,40          | 67,02             | 68,11                    | +21,71     |

# Tabela completa — F1 Next-POI (21 linhas)

| Estado · Categoria | Baseline (DGI) | ST-MTLNet (melhor) | Resultado  |
|--------------------|----------------|--------------------|------------|
| FL · Food          | 34,8           | 42,1               | vitória    |
| FL · Shopping      | 36,2           | 41,8               | vitória    |
| FL · Nightlife     | 29,4           | 33,2               | vitória    |
| FL · Travel        | 31,1           | 29,7               | derrota    |
| FL · Outdoors      | 30,40          | 30,38              | empate (σ) |
| FL · Community     | 33,5           | 39,4               | vitória    |
| FL · Entertainment | 32,1           | 36,9               | vitória    |
| CA · Food          | 29,0           | 51,0               | vitória    |
| CA · Shopping      | 34,1           | 40,2               | vitória    |
| CA · Nightlife     | 32,8           | 30,9               | derrota    |
| CA · Travel        | 30,5           | 28,7               | derrota    |
| CA · Outdoors      | 31,2           | 29,9               | derrota    |
| CA · Community     | 33,0           | 38,1               | vitória    |
| CA · Entertainment | 32,4           | 30,6               | derrota    |
| TX · Food          | 34,4           | 43,2               | vitória    |
| TX · Shopping      | 36,1           | 42,4               | vitória    |
| TX · Nightlife     | 30,2           | 34,1               | vitória    |
| TX · Travel        | 31,4           | 33,8               | vitória    |
| TX · Outdoors      | 30,9           | 32,7               | vitória    |
| TX · Community     | 33,2           | 38,8               | vitória    |
| TX · Entertainment | 32,7           | 36,4               | vitória    |

Totais: 15 vitórias estritas · 1 empate técnico (FL · Outdoors, Δ≈0,02 pp) · 5 derrotas

# Detalhe — SIREN

encoder espacial senoidal

Camada senoidal:

$$y = \sin(\omega \cdot Wx + b)$$

- Rede feed-forward com ativações  $\sin$
- Mapeamento  $f_\theta : \mathbb{R}^2 \rightarrow \mathbb{R}^{64}$
- Iniciações específicas para preservar a distribuição em camadas profundas

## Por que SIREN?

Forte em sinais de **alta frequência** sobre  $\mathbb{R}^2$  contínuo — útil para padrões urbanos finos.

**Referência:** Rußwurm '24

# Detalhe — Sphere2Vec-M

encoder esférico multi-escala

- 16 escalas geométricas entre 10 km e 10 000 km
- Coordenadas esféricas ( $\lambda$ ,  $\varphi$ )
- Termos de interação multi-escala
- Captura naturalmente **distância geodésica**

## Por que Sphere2Vec-M?

Não assume  $\mathbb{R}^2$ : trata a superfície terrestre como esfera. Forte em estados largos / sinais de longo alcance — **Texas é o exemplo.**

**Referência:** Mai '23



# Detalhe — Time2Vec

encoder temporal

Fórmula:

$$\begin{aligned} f(\tau)[i] &= \omega_0 \cdot \tau + \varphi_0 & \text{se } i = 0 \\ &= \sin(\omega_i \cdot \tau + \varphi_i) & \text{se } 1 \leq i \leq D-1 \end{aligned}$$

- Termo linear ( $i = 0$ ) captura **tendência**
- Termos senoidais capturam **ciclos** com fase e frequência *aprendidas*
- Generaliza encodings cíclicos fixos (sin/cos) — não há período *a priori*
- Em mobilidade: periodicidades não-óbvias (ex.: 4,5 dias) ficam dentro do modelo

# Detalhe — POI Encoder + HGI encoder categórico

- Random walks em **grafo Delaunay** dos POIs
- Skip-gram com **negative sampling**
- **HGI hierárquico** em 2 níveis: POI → região · região → cidade
- Mistura  $\alpha = 0,5$  entre níveis
- Captura tanto vizinhança fina quanto contexto urbano amplo

# Detalhe — NashMTL

balanceamento entre tarefas

- Barganha de Nash entre tarefas ( $K = 2$ : categoria, next-POI)
- Maximiza o **produto das utilidades de gradiente**
- Garante atualização **benéfica para todas as tarefas simultaneamente**
- Hiperparâmetros:  $\text{max\_norm} = 2, 2 \cdot \text{update\_weights\_every} = 4$

# Detalhe — Loss Contrastiva Binária

$$L_{loc} = - [ y \cdot \log \sigma(\text{sim} / \tau) + (1 - y) \cdot \log(1 - \sigma(\text{sim} / \tau)) ]$$

- Temperatura  $\tau = 0,15$
- $y = 1$  se  $\Delta d \leq \mathbf{10\ km}$  (par positivo)
- $y = 0$  se  $\Delta d \geq \mathbf{70\ km}$  (par negativo)
- Mesma estrutura aplicada para **Time2Vec** (par+ janela curta, par- janela longa)

# Hiperparâmetros de Treinamento

|                       |                                                                                            |
|-----------------------|--------------------------------------------------------------------------------------------|
| Otimizador            | AdamW $\text{lr}=1\text{e-}4 \cdot \text{weight\_decay}=0,05 \cdot \text{eps}=1\text{e-}8$ |
| Scheduler             | OneCycleLR $\text{max\_lr}=1\text{e-}3 \cdot 50 \text{ épocas}$                            |
| Batch                 | 2048                                                                                       |
| Gradient accumulation | 2 steps                                                                                    |
| MTL                   | NashMTL $\text{max\_norm}=2,2 \cdot \text{update\_weights\_every}=4$                       |

# Infraestrutura & Tempo de Treino

**GPU** *preencher · A40 / T4 (conforme rodado)*

**Tempo de treino** *preencher · ~h por (estado × encoder)*

**Memória pico** *preencher · GB*

*Valores serão completados quando consolidadas as execuções finais antes da publicação.*

# Ablação retórica

"e se zerássemos um encoder?"

| Encoder zerado                                                                               | Perda esperada                                   |
|----------------------------------------------------------------------------------------------|--------------------------------------------------|
|  Espacial   | Performance similar ao DGI (~ baseline)          |
|  Temporal   | Maior queda em next-POI; categoria pouco afetada |
|  Categórico | Perda em separabilidade entre classes próximas   |

*Ablação real está no roadmap — esta tabela orienta a expectativa.*

# Detalhamento do Split de Avaliação

- **5-fold** estratificado por categoria
- **Categoria:** divisão por POI (cada POI aparece em apenas um fold)
- **Next-POI:** janelas não-sobrepostas de tamanho  $L_h = 9$
- Usuários com  $< 5$  check-ins descartados
- **Class weights** aplicados na CE para mitigar desbalanceamento



# Posicionamento vs. baselines externos

| Baseline | Tarefa            | Granularidade  | Escopo desta comparação                   |
|----------|-------------------|----------------|-------------------------------------------|
| LSTPM    | Next-POI          | POI individual | Diferente — predizemos categoria, não POI |
| GETNext  | Next-POI          | POI individual | Mesmo motivo                              |
| STAN     | Next-POI          | POI individual | Mesmo motivo                              |
| HMT-GRN  | Next-POI + região | Multi-nível    | Próximo trabalho de comparação            |

*Justifica comparação direta apenas com MTLNet original, que opera no mesmo nível de granularidade (categoria).*