

Relatório de Evolução — Check2HGI + MTL Conjunto

{next_category, next_region} desde a submissão BRACIS 2026

Vitor Hugo

05 de junho de 2026

Guia de leitura e síntese para a fala estão no documento de apoio *report_05_06_notas.md*. Os números do “estado atual” (§6, correção C25, 2026-06-05) são **provisórios** / **em re-validação** — ver a Tabela 8 e suas ressalvas.

Parte I — Estado do artigo (*baseline* v11)

A versão canônica do artigo é a **v11** (“*paper canon*”, congelada). Todos os números abaixo vêm de *docs/results/RESULTS_TABLE.md* §0.1 — multi-seed **n=20** (sementes {0,1,7,100} × 5 *folds*), substrato GCN, log_T-KD desligado.

1 Resultados do artigo (v11)

Tabela 1: **v11 — tabela arquitetural §0.1 (5 estados, n=20)**. reg = Acc@10 (%); cat = macro-F1 (%). Δ = MTL – STL. Todos os $p \leq 2 \times 10^{-6}$ (Wilcoxon pareado, n=20).

Estado	#reg.	next-region (Acc@10)			next-category (macro-F1)		
		MTL	STL	Δ reg	MTL	STL	Δ cat
AL	1.109	50,17	61,21	−11,04	40,57	41,35	−0,78
AZ	1.547	40,78	53,06	−12,27	45,10	43,90	+1,20
FL	4.703	63,27	70,62	−7,34	68,56	67,16	+1,40
CA	8.501	47,35	56,85	−9,50	64,07	62,39	+1,68
TX	6.553	42,84	59,44	−16,59	65,00	63,11	+1,89

Leitura do *baseline*.

- **Região (reg):** o MTL fica **−7 a −17 p.p. abaixo** do *single-task* em todos os 5 estados (sinal consistente). Este é o “gap” que o artigo declarou como **limitação** — e que a Parte II mostra ser, em grande parte, artefato metodológico.
- **Categoria (cat):** o MTL **empata ou supera** o STL em 4 dos 5 estados (AZ/FL/CA/TX). AL é a exceção (−0,78 p.p.) — e mesmo essa exceção some sob a receita corrigida (§6.7).

1.1 Substrato: Check2HGI vs. HGI (single-task, §0.3)

O substrato Check2HGI (*embeddings* contextuais *por check-in*) é a base do paper. Contra o HGI (POI-level), a vantagem é *enorme em categoria* e *neutra em região*:

Tabela 2: STL *matched-head*, substrato Check2HGI vs. HGI (§0.3). cat: Wilcoxon $p = 0,0312$ (5/5 *folds*) em todos os estados. reg: HGI nominalmente acima por 1,6–3,1 p.p. (TOST).

Estado	cat macro-F1			reg Acc@10		
	C2HGI	HGI	Δ	C2HGI	HGI	Δ
AL	41,35	25,26	+15,50	59,15	61,86	−2,71
AZ	43,90	28,69	+14,52	50,24	53,37	−3,13
FL	63,43	34,41	+29,02	69,22	71,34	−2,12
CA	59,94	31,13	+28,81	55,92	57,77	−1,85
TX	60,24	31,89	+28,34	58,89	60,47	−1,59

Lição que guiou tudo depois: o Check2HGI domina em *categoria* (a intenção categórica varia por visita; o HGI destrói isso por construção), mas em *região* o sinal não vive na geometria do *embedding* — vive no *operador de transição* (a matriz Markov $\log T$). Esse é o ponto de partida da nova metodologia de avaliação (§3.1).

1.2 Baselines de referência

Tabela 3: Pisos e teto neural para region (Acc@10), por estado.

Baseline	AL	AZ	FL	CA	TX
Markov-1-region (piso clássico)	47,01	42,96	65,05	52,09	54,94
STAN (Luo, WWW 2021, adaptado)	59,20	52,24	72,62	58,82	61,35

FL é o “regime denso”: Markov-1-region satura em $\sim 65\%$ — $\sim 85\%$ das linhas de validação têm a região anterior já vista no treino. Assumido como limitação no paper.

2 Metodologia antiga

2.1 Arquitetura Check2HGI (substrato)

Estende o HGI (*Hierarchical Graph Infomax*) de 3 para 4 níveis, deslocando a granularidade do *embedding* de POI para **check-in**:

$$\text{Check-in} \rightarrow \text{POI} \rightarrow \text{Região (census tract)} \rightarrow \text{Cidade}$$

Cada nó é um **evento de check-in**; *features* = *one-hot* de categoria + 4 dim temporais (sin / cos de hora e dia-da-semana); arestas de sequência do usuário pesadas por $\exp(-\Delta t/\tau)$. *Encoder* GCN 2-camadas $\rightarrow$ vetor de dim $D = 64$ por check-in. Perda contrastiva *mutual-information* em 3 fronteiras simultâneas ($\alpha_{c2p}, \alpha_{p2r}, \alpha_{r2c}$). O mesmo POI, visitado em contextos diferentes, gera vetores distintos — propriedade que o HGI não produz.

2.2 Arquitetura MTL (*champion* do paper)

Componente	Escolha
Arquitetura	mtlnet_crossattn — 2 blocos de <i>cross-attention</i> bidirecional ($d = 256$, 8 cabeças)
Loss MTL	static_weight: $\mathcal{L} = 0,75 \mathcal{L}_{\text{cat}} + 0,25 \mathcal{L}_{\text{reg}}$
Cabeça cat (task_a)	next_gru (GRU 1-camada sobre a janela de 9 check-ins)
Cabeça reg (task_b)	next_getnext_hard (STAN + <i>prior</i> aditivo $\alpha \cdot \log T$)
Input por tarefa	cat $\leftarrow$ <i>embedding</i> check-in; reg $\leftarrow$ <i>embedding</i> região

Em vez de um *backbone* compartilhado monolítico (FiLM/MMoE/CGC), os dois *streams* (um por tarefa) trocam informação *por conteúdo* via *cross-attention* — cada cabeça recebe sua modalidade

preferida e é informada pela outra tarefa. A cabeça de região soma um *prior* estatístico de transições $\alpha \cdot \log T[r_{\text{último}}]$ (GETNext-style).

2.3 Os dois defeitos metodológicos descobertos depois

Estes dois defeitos — presentes na metodologia que produziu os números v11 — são a razão do “gap” de região. Corrigi-los é o que reescreve a história (Parte II).

(A) A fórmula do *joint* estava errada (seletor de *checkpoint*, C21).

Para *implantar* um único modelo, é preciso escolher *uma* época que sirva às duas tarefas. O seletor antigo era a média aritmética $\frac{1}{2}(\text{cat_F1} + \text{reg_F1})$ — mas as duas métricas vivem em escalas diferentes, e “reg_F1” não é a métrica reportada (Acc@10). O seletor correto é a **média geométrica alinhada à *headline***:

$$\text{geom_simple} = \sqrt{\text{cat_macroF1} \cdot \text{reg_Acc@10}}.$$

A troca **recuperou +5,6 p.p. de reg implantável** (FL multi-seed). *Importante: a §0.1 em si não usa esse seletor (ela reporta a melhor época por tarefa = “disjoint”, independente do seletor); o bug afeta apenas o número conjunto/implantável.*

(B) O método de *loss* das cabeças estava desalinhado da métrica (C25, descoberto 2026-06-05).

A cabeça de região era treinada (silenciosamente, por um *default* não-documentado `use_class_weights=True`) com **CrossEntropy ponderada por classe**, enquanto (i) o teto *single-task* e (ii) a própria métrica reportada **Acc@10** são *não-ponderados*. Balancear por classe otimiza a acurácia *macro* e **afasta do top-K** — deprimindo a reg do MTL em **~10–14 p.p.** (pior quanto mais classes/regiões, i.e. maior em FL). **Esse confound — não a arquitetura, não o substrato, não o loop conjunto — era essencialmente todo o “gap MTL→STL de região”.** A correção (ambas as cabeças não-ponderadas) é detalhada na §6.

2.4 Avaliação: *disjoint* vs. *jointly*

Toda corrida MTL é reportada em dois “*fronts*”, e a diferença entre eles quantifica o custo de servir um *único checkpoint*:

- ***disjoint*** (diagnóstico / teto-oráculo): cada cabeça avaliada na sua própria melhor época — são *dois checkpoints*. Mede a capacidade máxima de cada tarefa.
- ***jointly*** (implantável): as duas cabeças no *mesmo checkpoint* único, escolhido por `geom_simple`. É o número honesto de “um modelo, duas tarefas”.

O defeito (A) acima é exatamente o seletor do front jointly.

Parte II — Estado atual

3 Melhorias no Check2HGI (substrato)

3.1 Nova metodologia de avaliação de *embeddings*: a escada L0–L3

Problema que resolve. Antes, julgávamos um substrato treinando uma cabeça STL completa (`next_gru`, `next_stan_flow`) sobre *embeddings* congelados. Isso **confunde três coisas** — qualidade do *embedding*, capacidade da cabeça, e o regime STL≠MTL — e já tínhamos um contraexemplo (ResLN/Design-B é o melhor substrato STL mas *não* dá ganho em MTL). Uma única nota STL de cabeça-forte podia *coroar o vencedor errado*. A escada separa esses confounds:

Tabela 4: A escada L0–L3 de avaliação de substrato.

Nível	O que isola	Protocolo	Custo
L0	Geometria pura (sem treino)	kNN-LOO, <i>silhouette</i> , separação de centroides, CKA, coerência de adjacência — <i>zero confound</i> de cabeça	segundos
L1	Sinal linearmente acessível	<i>embeddings</i> congelados → uma camada Linear softmax, multi-seed	minutos
L2	Tarefa sequencial real vs. capacidade da cabeça (uma <i>curva</i>)	escada de cabeça: Linear → next_gru → next_stan_flow (STL)	horas-GPU
L3	Objetivo conjunto implantado	a corrida MTL {cat,reg} sob a receita NORTH_STAR	horas-GPU

Correção crucial de especificidade por tarefa. Para **next-cat** (atributo estático do POI), L0 já é um *ranqueador* quase-suficiente — o alvo está na geometria. Para **next-reg** (transição), *nenhuma* métrica de geometria estática ranqueia substratos: o alvo vive em $\log T$, não na geometria (correlação $\approx 0,05$ entre cosseno de regiões e T_{ij} para *todo engine*). Logo, ranqueamento de região começa só no **L2**. Essa é a razão de muitas hipóteses de substrato falharem em região (abaixo).

3.2 Hipóteses de melhoria testadas (a jornada, incluindo o que deu errado)

Exploramos um espaço grande de melhorias de substrato. A maioria **não** moveu as tarefas *downstream* (ou vazou). Resumo honesto — útil para delimitar o espaço de busca e mostrar rigor:

Tabela 5: Principais hipóteses de substrato/arquitetura e seus veredictos. “vazamento” = ganho ilusório por *label leak* (descartado).

Hipótese	Veredicto	Evidência / motivo
merge_design B/H/I/J/M (POI2Vec injetado na fronteira de <i>pooling</i>)	STL+ / MTL-nulo	Pareto sobre canônico em STL ($\sim +2$ p.p. reg); <i>não</i> bate HGI; some no MTL
Design A (<i>late-fusion</i> na cabeça)	falsificado	cat -9 / reg -10 p.p.
Design D (heterografo, arestas reversas)	vazamento	$+20$ p.p. de <i>leak</i> no <i>probe</i> de último passo
GATv2 (atenção no grafo)	vazamento	<i>leak</i> estrutural catastrófico (cat $\rightarrow 99\%$)
R-GCN ($K=2$)	vazamento	$+27,85$ p.p. de <i>leak</i> ; $K=1$ colapsa
Time2Vec / GraphMAE / POI <i>side-feats</i>	falsificado	perde cat ou não replica entre estados
hgi_category_injection (6 variantes)	falsificado	melhor (D_orth) cat $+0,36$ / reg $+0,10$ (ruído)
<i>Balanced sampler</i> na cabeça reg (MTL)	falsificado	-18 a -30 p.p.
Delaunay POI-POI GCN (arestas espaciais)	revivido	falsificado em AL/AZ; re-validado em FL — o eixo espacial que faltava
ResLN (<i>encoder</i> residual + Layer-Norm)	promovido (STL)	melhor <i>encoder</i> de cat STL ($+0,9$ a $+1,7$ p.p.); STL-only

O ponto-chave: **Delaunay** (importar o grafo espacial do HGI como arestas POI-POI) foi *descartado cedo* num estudo AL/AZ-only, e **re-validado em FL** graças à escada L0–L3 — é a única alavanca que se traduziu em região (L2). Isso virou o substrato **v14**.

4 Resultados após melhorias no Check2HGI (v14)

v14 = **check2hgi_design_k_resln_mae_l0_1**: três eixos ortogonais empilhados — **ResLN** (+cat, via *encoder*) $\oplus$ **Delaunay POI-GCN** (+reg, caminho de região destacado) $\oplus$ **mae** (recon. mas-

carada de agregado de categoria, +cat marginal).

4.1 STL next-cat e STL next-reg (FL, leak-free, multi-seed)

Tabela 6: Substratos no FL (leak-free, multi-seed $\{0,1,7,100\}$). v14 é o campeão *dual-axis*: mantém a liderança esmagadora em cat e fecha a maior parte do gap de reg para o HGI.

Engine	next-cat F1	next-reg Acc@10
canonical (Check2HGI)	~64,6	0,6943
design_k (gcn+Delaunay)	64,82	0,7034
design_k+resln	66,95	0,7020
design_k+resln+mae (v14)	67,36	0,7024
HGI	34,29	0,7060

Leitura. cat: v14 **67,36** $\approx$ canônico-congelado e $\gg$ HGI (34,29; +33 p.p.). reg: v14 **0,7024** fica +0,81 p.p. sobre o canônico e **fecha** $\sim 69\%$ do gap canônico $\rightarrow$ HGI; resta $-0,36$ p.p. para o HGI (e plain design_k(gcn) fecha $\sim 78\%$ em 0,7034, mas custa $-2,5$ p.p. de cat — por isso a escolha *dual-axis* é o v14).

4.2 Tetos *single-task* congelados (a régua interna)

As corridas posteriores são medidas contra estes tetos STL *congelados* (régua imutável):

Tabela 7: Tetos STL congelados. reg = `next_stan_flow` com $\alpha=0$ (*prior* OFF); cat = `next_gru` com *logit-adjust* $\tau=0,5$. (c) = teto por tarefa; (d) = *composite* de 2 modelos (cat-v14 $\oplus$ reg-melhor). Seed=42.

	AL	AZ	GE [†]	FL
(c) cat macro-F1	49,97	51,01	58,12	69,97
(c) reg Acc@10	62,88	55,11	58,45	73,31
(d) <i>composite</i> reg	63,58	55,11	58,76	73,62

[†] GE (Georgia, ~ 2.283 regiões) é um estado intermediário novo, criado 2026-06-03 para testar a hipótese de escala; não está no paper.

5 Melhorias no single-task (STL)

Duas alavancas de *tuning* (não-arquiteturais) elevaram os tetos STL — e, no caminho, *esvaziaram* a vantagem aparente de substrato em região:

reg: $\alpha=0$ — desligar o *prior* aditivo $\log T$.

O *prior* estatístico de transições, somado como $\alpha \cdot \log T$, é um **lastro líquido** no teto STL de região: desligá-lo ($\alpha=0$) ganha +0,56 (AL) a +3,03 p.p. (FL). Surpreendente: quando α é *aprendível*, ele converge *grande* (AL 0,45 $\rightarrow$ FL 1,09) — o modelo “apoia-se” no *prior* — e *mesmo assim* generaliza pior que o *encoder* puro. *Interpretação honesta: o prior carrega sinal real (sozinho bate o piso Markov-1-region), mas como viés aditivo fixo ele atrapalha um encoder que já modela transições. O mecanismo exato (gap treino/val vs. double-counting) não foi isolado.*

cat: *logit-adjustment* $\tau=0,5$ (Menon, ICLR 2021).

Ajuste de *logits* por frequência de classe (sem *class-weighting*/focal/*label-smoothing*, que *pioram* quando empilhados): +1,9 a +4,0 p.p. de macro-F1 em todos os estados.

Consequência forte (eixo de substrato esgotado). Uma vez que *ambos* os substratos estão $\alpha=0$ -endurecidos, **v14** $\approx$ **HGI** em reg STL (todo $\Delta \leq 0,70$ p.p. e $< 0,5\sigma$). A “vantagem de substrato” do **HGI** em região era um artefato do *prior* $\log T$. Isso reforça a tese central: o gap de região *não* é substrato — é arquitetural/protocolo (Parte II, §6).

6 Melhorias no MTL — o achado central (correção C25)

6.1 A hipótese antiga e sua queda

A leitura anterior (“*regime finding*”) era: o gap de região -7 a -17 p.p. é **irredutivelmente arquitetural** (o *pathway* de região do *backbone* compartilhado), os ganhos de substrato “lavam” no MTL, e a resposta de *deploy* seria o *composite* de *dois* modelos. **Isso caiu em 2026-06-05.**

6.2 O confound de *class-weighting* (C25) e a correção

A causa do gap era o defeito (B) da §2.3: a cabeça de região treinava com CE *ponderada por classe*, enquanto a métrica Acc@10 e o teto STL são *não-ponderados*. A correção é **ponderação por tarefa, ambas as cabeças não-ponderadas** por *default*. Verificado: com `-no-class-weights`, a reg do MTL **alcança/supera** o teto STL (ex. AL: de 52,90 “bugado” $\rightarrow 64,81 \geq 62,88$). A correção da cabeça de *categoria* também é um ganho real (+3 a +5 p.p. macro-F1 — a hipótese de que “balancear ajuda macro-F1” foi testada e é *falsa*).

6.3 Números re-validados (multi-seed, não-ponderado, AL/GE/FL)

Tabela 8: **Estado atual do MTL (provisório).** Multi-seed $\{0,1,7,100\}$, *real-joint* não-ponderado, substrato v14, front *jointly*/implantável (seletor `geom_simple`). (+/−) = Δ vs. o teto/composite da mesma coluna.

Estado	next-region (Acc@10)			next-category (macro-F1)	
	MTL (v14)	teto STL (c)	composite (d)	MTL (v14)	teto STL cat
AL	64,52	62,88 (+1,6)	63,58 (+0,9, supera)	53,38	49,97 (+3,4)
GE	57,84	58,45 (−0,6)	58,76 (−0,9)	61,37	58,12 (+3,2)
FL	71,55	73,31 (−1,8*)	73,62 (−2,1)	71,89	69,97 (+1,9)

* O resíduo de $-1,8$ p.p. em FL é o *prior* $\alpha \cdot \log T$ (*prior*-OFF fecha $\sim 80\%$) e é **fechado pelo dual-tower** (FL 73,06, $-0,25$ vs. teto) — não é um limite fundamental do MTL.

Sobre *disjoint* vs. *jointly* (nota de honestidade). A re-validação corrigida reportou, até agora, apenas o front *jointly*/implantável (acima). O *split* 2×2 $\{\text{cat, reg}\} \times \{\text{disjoint, jointly}\}$ **sob a receita corrigida ainda está pendente** — o *split disjoint/jointly* disponível hoje é o da receita *antiga* (ponderada), que foi **deliberadamente excluído** por carregar o *confound* C25. Como o front *jointly* é o número de *deploy* (e o mais conservador dos dois), ele é o reportado; o *disjoint* corrigido é uma das pendências (§8). *Referência: na receita antiga, o gap disjoint–jointly media o custo de servir um único checkpoint (§2.4); espera-se que ele encolha sob a correção.*

6.4 O que isto reescreve (claim a claim)

Tabela 9: O efeito-dominó da correção C25 sobre as conclusões do paper.

Conclusão antiga	Nova (corrigida)	Veredicto
“MTL sacrifica reg -7 a -17 p.p.” (§0.1)	MTL reg $\approx$ teto STL (AL +1,6 / GE -0,6 / FL -1,8); §0.1 reg sobe +10 a +13 p.p.	DISSOLVIDO
“Ganho de substrato lava no MTL” (<i>regime finding</i>)	$\Delta\text{reg}(\text{v14}-\text{canônico}) = +1,92/+1,49/+0,81$ — o substrato transfere	SUPERADO
“ <i>Composite</i> (2 modelos) = +7 a +12 p.p.; implante 2 modelos”	1 modelo MTL $\geq$ <i>composite</i> (AL +0,94; GE/FL dentro de 1-2 p.p.)	DISSOLVIDO
“ <i>Dual-tower</i> perde; gap irreduzível”	<i>Dual-tower</i> fecha o gap (FL +1,51 vs. base; -0,25 vs. teto); ordenações invertiram	SUPERADO
“MTL cat” (§0.1)	MTL cat supera o teto STL de cat em todos os estados (+2 a +3,5 p.p.)	RE-AFIRMADO ↑

6.5 O *dual-tower*: fechando o último resíduo (FL)

O que é (breve). O *dual-tower* dá à tarefa de região uma *torre própria* — um *backbone* STAN completo e *privado*, que opera sobre o *input* de região cru — em paralelo à *torre compartilhada* (a *cross-attention* que serve as duas tarefas). Uma fusão com *gate* aprendível combina as duas: a cabeça de região deixa de ser “diluída” pelo compartilhamento com a categoria, mas *ainda* recebe contexto cruzado da categoria via o *gate*. É a peça que, sob a receita corrigida, fecha o último resíduo de região no estado grande (FL).

As ordenações inverteram. Sob a receita *antiga* (ponderada, com o *confound* C25), o *dual-tower* era o *pior* ponto da curva de compartilhamento (-2,89 p.p. em FL) — e foi por isso que a leitura anterior o declarou “derrotado, gap irreduzível”. Sob a correção, ele vai de **pior a melhor**:

Tabela 10: Re-run da arquitetura Tier-2 sob a correção (FL, não-ponderado, multi-seed {0,1,7,100}). Teto STL (c) = 73,31. As ordenações inverteram vs. a receita antiga (onde o *dual-tower* era o pior, -2,89).

Arquitetura (FL)	reg Acc@10	Δ vs. base	gap vs. teto (c)
<i>dual-tower</i> com <i>gate</i> (T2.1)	73,06	+1,51	-0,25
<i>prior</i> -OFF (base, $\alpha=0$)	72,94	+1,39	-0,37
<i>cross-stitch</i> (T2.2)	71,98	+0,43	-1,33
base_a (ref., <i>prior</i> -ON)	71,55	0	-1,76
<i>hard-share</i> (T2.0)	71,48	-0,07	-1,83

Leitura. Combinando com a Tabela 8: **o gap MTL→STL de região fecha nos 3 estados com um único modelo** — AL 64,52 (+1,6 vs. teto, já com **base_a**); GE 57,84 (-0,6); FL 73,06 (-0,25, com *dual-tower*). O que era um “gap arquitetural irreduzível de -7 a -17 p.p.” virou $\leq 0,6$ p.p. (≈ 0 dentro do ruído multi-seed). *O combo dual-tower + prior-OFF não empilha (73,01 $\approx$ 73,06): a torre privada já captura o benefício do prior-OFF. Escopo: o dual-tower foi rodado em FL multi-seed; em AL/GE o base_a já atinge o teto, então a torre privada não foi necessária.*

6.6 O número do artigo, antes e depois da correção (mesmo substrato v11)

Para a comparação *maçã-com-maçã* (mesmo substrato GCN do paper, só corrigindo o *loss*), o gap de região do *baseline* essencialmente **some**:

Tabela 11: Re-statement da reg do MTL na §0.1 (substrato v11 GCN, multi-seed, não-ponderado). O “gap” arquitetural vira “ $\approx$ teto STL”. Tetos STL de ambos os substratos para referência (C2HGI = §0.1; HGI = §0.3, *next_stan_flow matched-head*).

Estado	§0.1 v11 (ponderado, <i>bug</i>)	§0.1 corrigido (não-pond.)	teto STL C2HGI	teto STL HGI
AL	50,17 (−11,04)	62,60	61,21	61,86
FL	63,27 (−7,34)	70,74	70,62	71,34

Leitura. A reg do MTL corrigida (62,60 AL / 70,74 FL) **ultrapassa** o teto STL do próprio substrato do paper (C2HGI: 61,21 / 70,62) e fica praticamente *no* teto do *melhor* substrato single-task (HGI: 61,86 / 71,34; −0,24 AL / −0,60 FL). I.e. o número do artigo, só corrigindo o *loss*, deixa de “sacrificar região” e passa a empatar o melhor single-task possível.

Disciplina de números (não confundir). Há dois conjuntos corrigidos distintos: (i) substrato v11 GCN não-ponderado — AL 62,60 / GE 56,34 / FL 70,74 — é o número *do artigo* após a correção (só o *bug*); (ii) substrato v14 não-ponderado — AL 64,52 / GE 57,84 / FL 71,55 — *empilha* o ganho de substrato por cima. Os 50,14/37,78/61,21 do antigo “board v14” são *pré-correção* (ponderados) e **não** devem ser citados como estado atual.

6.7 Outras melhorias MTL (receita)

- **onecycle (nova receita de estado pequeno).** Agenda agressiva sem *alternating-optimizer-step*: domina a H3-alt e bate a B9 em AL/AZ (+6 a +9 p.p. reg / +1 a +2 p.p. cat em v14 multi-seed). O *alt-opt inverte de sinal por escala* (pune cat em estado pequeno) — por isso a B9 fica nos estados grandes (FL/CA). *Isso também explica a exceção AL −0,78 da §0.1: era artefato da receita B9 em estado pequeno, não da tarefa.*
- **log_T-KD $W=0,2$ ($\tau=1,0$).** Destilação KL do *prior* $\log T$ por *fold* (apenas-treino) nos *logits* de região: **paper-grade** em estado pequeno (+2,27 AL / +4,91 AZ, $n=20$, $p \approx 10^{-6}$, auditado sem vazamento); *pilot* em FL (+2,40). É a alavanca confirmada que vive no *pathway do prior*, não no *encoder*. *Em STL o $\log T$ aditivo atrapalha; em MTL como loss de KD ajuda — não é contradição, são mecanismos distintos.*

Parte III — Melhorias futuras

7 Janelas sobrepostas (*stride*=1 vs. *stride*=9): um teto escondido

O achado. `generate_sequences` usa *stride* = tamanho-da-janela = 9, i.e. janelas **não-sobrepostas**: um usuário com N check-ins gera $\sim N/9$ sequências em vez de $\sim N$. Em Alabama: 113.846 check-ins $\rightarrow$ apenas **12.709** sequências de treino. Com *stride*=1 (sobreposto): ~ 108.073 — um aumento de **7,5–8,4 $\times$** na supervisão (história $\rightarrow$ próximo). Não-sobrepôr **não** é padrão na literatura de next-POI (STAN/GETNext/DeepMove usam *stride* 1). E o teto é **independente da cabeça** — por isso nenhuma troca de cabeça revelou esse limite.

Leak-safe. A CV é `StratifiedGroupKFold(groups=userid)`: todas as janelas de um usuário caem no *mesmo fold* $\rightarrow$ sobreposição *não* cruza treino/val (efeito de variância, não viés para cima).

Tabela 12: Validado em AL (*pipeline* real). $\Delta = \text{stride}=1 - \text{stride}=9$.

Métrica	não-sobreposto	sobreposto (<i>stride</i> =1)	ganho
STL cat (<i>next_gru</i>)	49,97	59,74	+9,77
STL reg (v14)	62,88	68,01	+5,13
STL reg (HGI)	63,58	68,47	+4,89
MTL cat (<i>joint/disjoint</i>)	46,30 / 46,52	55,21 / 55,90	+8,9/+9,4
MTL reg (<i>joint/disjoint</i>)	54,54 / 53,47	55,05 / 54,46	+0,5/+1,0

Por que isto *fortalece* a tese (a parte importante).

- **cat = maré que sobe:** a sobreposição eleva cat quase igual em STL (+9,8) e MTL (+8,9) — o *pathway* de categoria do MTL aproveita o dado extra.
- **reg = o gap STL→MTL *alarga*:** a sobreposição eleva o STL reg (+5,1) mas o MTL reg quase não move (+0,5). O gap STL→MTL passa de 8,34 → 12,96. O *backbone* compartilhado *não absorve* o dado extra — evidência direta a favor do *dual-tower*.

Escala-dependente: AL (pequeno) cat +9,77; FL (grande) só +1,30 (perto de saturação). A decisão foi manter a canon não-sobreposta (consistência de todo o estudo: tetos congelados, board, log_T por fold e a §0.1 do paper são todos não-sobrepostos). Adotar exigiria reconstruir todos os números.

8 Pendências para fechar o ciclo

1. **Re-validar AZ/CA/TX** sob a receita corrigida (não-ponderada) — hoje só AL/GE/FL.
2. **Continuidade de receita:** re-rodar a §0.1 em FL com a receita B9 exata (a re-validação usou *onecycle*) antes de substituir a tabela do paper.
3. **Dual-tower + prior-OFF** (FL multi-seed) para confirmar o fechamento completo do resíduo de FL.
4. **Correção do monitor de *checkpoint* de reg** (Acc@1 → Acc@10) para os números implantáveis.
5. **Congelar** uma nova versão canônica para a receita não-ponderada e promovê-la ao NORTH_STAR; **re-pin** da §0.1.